

Homework 1: Stock Prediction

314833005 李郡益

April 3, 2026

1 前言與目標 (Introduction)

本實驗以台積電股票 (2330.TW) 為預測目標，採用涵蓋注意力機制 (Attention Mechanism) 的長短期記憶網路 (LSTM) 模型，對股票收盤價進行時間序列預測。透過超參數調整與滾動預測模擬，探討模型在實際金融場景中的應用潛力，同時驗證模型預測結果對投資決策的實用性。

2 基準 (Baseline)

以原始程式碼為基準，輸入特徵僅使用台積電收盤價 (Close Price)，並以 MinMaxScaler 正規化至 $[0, 1]$ 。模型架構與訓練參數設定如下：

- Sequence Length (look_back) : 100 天
- 模型架構 : LSTM(128) $\rightarrow$ LSTM(64) $\rightarrow$ Attention $\rightarrow$ Dense(1)
- Optimizer : Adam (LR = 0.001)
- Loss Function : Mean Squared Error (MSE)
- Epochs : 50 , Batch Size : 32

Baseline 模型之評估結果如表 1 所示。

Table 1: Baseline 模型評估結果			
資料集	RMSE	MAE	MAPE
Train	13.9449	11.0807	1.89%
Test	28.5012	22.3481	1.78%

由結果可觀察到，訓練集 RMSE (13.94) 低於測試集 RMSE (28.50)，顯示模型在訓練資料上擬合良好，但在未見資料上誤差有所上升，初步判斷模型存在輕微過擬合 (Overfitting) 現象，後續將透過超參數調整加以改善。

3 超參數調整 (Hyperparameter Tuning)

3.1 Sequence Length (look_back) 調整

本實驗固定其餘參數不變 (LSTM [128, 64]、LR = 0.001、Batch = 32、Epochs = 50)，僅調整輸入序列長度 look_back，分別測試 60、90、120 天三種設定，與 Baseline (100 天) 進行比較，結果如表 2 所示。

Table 2: 不同 look_back 設定之模型評估結果

look_back	Epochs	Train RMSE	Train MAPE	Test RMSE	Test MAPE
100 (Baseline)	50	13.9449	1.89%	28.5012	1.78%
60	22	18.5258	2.53%	55.6096	2.62%
90	50	12.3779	1.62%	45.9195	2.14%
120	40	16.6013	3.41%	47.1903	2.16%

實驗結果顯示，Baseline 的 look_back = 100 在測試集上取得最低 RMSE (28.50) 與最低 MAPE (1.78%)，表現優於其他三種設定。look_back = 60 僅訓練 22 個 Epoch 即提前停止，且測試 RMSE 高達 55.61，顯示過短視窗難以捕捉趨勢，收斂不穩定。look_back = 90 與 120 訓練誤差相對較低，但測試 RMSE 均超過 45，推測中長視窗在本次資料集下引入較多遠期雜訊，削弱近期趨勢的學習效果。因此後續實驗維持 look_back = 100 的設定。

3.2 模型架構 (LSTM Units) 調整

本實驗固定 look_back = 100，調整 LSTM 層的神經元數量與堆疊層數，分別測試四種架構與 Baseline ([128, 64]) 進行比較，結果如表 3 所示。

Table 3: 不同 LSTM 架構之模型評估結果 (look_back = 100)

LSTM 架構	Epochs	Train RMSE	Train MAPE	Test RMSE	Test MAPE
[128, 64] (Baseline)	50	13.9449	1.89%	28.5012	1.78%
[64, 32]	50	15.2279	2.28%	47.7852	2.21%
[256, 128]	18	18.8545	3.00%	59.3027	2.80%
[128, 64, 32]	37	17.5951	2.46%	63.0979	2.92%
[256, 128, 64]	50	14.1396	2.50%	42.0003	1.95%

實驗結果顯示，Baseline 架構 [128, 64] 在測試集上表現最佳 (RMSE = 28.50，MAPE = 1.78%)。[256, 128] 僅跑 18 個 Epoch 即停止，測試 RMSE 高達 59.30，推測較大的網路在資料量有限時容易過擬合且難以收斂。[128, 64, 32] 同樣提前停止 (37 Epochs)，測試 RMSE 更升至 63.10。[256, 128, 64] 雖完整跑完 50 Epochs，測試 RMSE (42.00) 與 MAPE (1.95%) 相對較優，但仍不及二層 Baseline。整體而言，[128, 64] 的二層中型架構最為穩定，後續維持此設定。

3.3 訓練參數 (Learning Rate、Batch Size、Epochs) 調整

本實驗固定 look_back = 100、LSTM [128, 64]，調整學習率、Batch Size 與 Epochs，結果如表 4 所示。

Table 4: 不同訓練參數之模型評估結果 (look_back = 100)

LR	Batch	Epochs	Train RMSE	Train MAPE	Test RMSE	Test MAPE
0.001 (Baseline)	32	50	13.9449	1.89%	28.5012	1.78%
0.0005	32	55	15.3130	2.62%	44.5330	2.07%
0.005	32	50	10.9902	1.65%	32.1962	1.57%
0.001	16	50	12.1740	1.57%	35.4969	1.71%
0.001	64	36	19.1805	3.59%	51.6121	2.34%
0.001	32	45	14.4624	2.01%	44.1821	2.03%

本實驗中，LR = 0.005 的測試 RMSE (32.20) 與 MAPE (1.57%) 均優於 Baseline，顯示較高的學習率在本資料集下有助於更快找到較佳的極小值。Batch = 16 的測試 RMSE (35.50) 與 MAPE (1.71%) 亦優於 Baseline，小批次帶來的梯度雜訊具有一定的正則化效果。LR = 0.0005 收斂過慢 (55 Epochs)，測試 RMSE 反而升至 44.53。Batch = 64 提前在 36 Epochs 停止，測試 RMSE (51.61) 最差。Epochs = 100 實際跑 45 Epochs 即停止，測試 RMSE 達 44.18，並未帶來進一步改善。

3.4 Dropout 正則化調整

本實驗固定 look_back = 100、LSTM [128, 64]，於每個 LSTM 層後加入 Dropout 層，分別測試三種比率，結果如表 5 所示。

Table 5: 不同 Dropout Rate 之模型評估結果 (look_back = 100)

Dropout Rate	Epochs	Train RMSE	Train MAPE	Test RMSE	Test MAPE
無 (Baseline)	50	13.9449	1.89%	28.5012	1.78%
0.1	25	25.5733	4.80%	63.1729	2.95%
0.2	60	17.7303	3.01%	49.8803	2.34%
0.3	22	34.3331	4.86%	127.6855	6.24%

加入 Dropout 後各項指標全面惡化，尤其 Dropout = 0.3 的測試 RMSE 暴增至 127.69，且僅跑 22 個 Epoch 即停止收斂。推測原因為台積電股價具有較強的趨勢連續性，Dropout 隨機丟棄神經元的機制破壞了 LSTM 對時間序列的記憶能力。因此本資料集不適合加入 Dropout 作為正則化手段，後續最佳模型維持無 Dropout 設定。

3.5 超參數調整總結

綜合四項實驗，表 6 彙整所有設定與對應表現。

Table 6: Phase 1 超參數調整總結

設定	look_back	LSTM	Dropout	Epochs	Test RMSE	Test MAPE
Baseline	100	[128,64]	無	50	28.5012	1.78%
look_back = 60	60	[128,64]	無	22	55.6096	2.62%
look_back = 90	90	[128,64]	無	50	45.9195	2.14%
look_back = 120	120	[128,64]	無	40	47.1903	2.16%
LSTM [64, 32]	100	[64,32]	無	50	47.7852	2.21%
LSTM [256, 128]	100	[256,128]	無	18	59.3027	2.80%
LSTM [128, 64, 32]	100	[128,64,32]	無	37	63.0979	2.92%
LSTM [256, 128, 64]	100	[256,128,64]	無	50	42.0003	1.95%
LR = 0.0005	100	[128,64]	無	55	44.5330	2.07%
LR = 0.005	100	[128,64]	無	50	32.1962	1.57%
Batch = 16	100	[128,64]	無	50	35.4969	1.71%
Batch = 64	100	[128,64]	無	36	51.6121	2.34%
Epochs = 100	100	[128,64]	無	45	44.1821	2.03%
Dropout = 0.1	100	[128,64]	0.1	25	63.1729	2.95%
Dropout = 0.2	100	[128,64]	0.2	60	49.8803	2.34%
Dropout = 0.3	100	[128,64]	0.3	22	127.6855	6.24%

根據上述四項實驗，Baseline 設定（look_back = 100、LSTM [128, 64]、Epochs = 50、無 Dropout）在測試集 RMSE 上仍為最佳（28.5012）。各實驗主要結論如下：

- **Sequence Length**：look_back = 100 表現最佳，過短（60）導致提前停止與測試誤差暴增，過長（90、120）引入遠期雜訊。
- **LSTM 架構**：[128, 64] 的二層中型架構最為穩定；更大或更深的網路容易提前停止或訓練不穩定。
- **訓練參數**：LR = 0.005 與 Batch = 16 在測試 MAPE 上優於 Baseline，但測試 RMSE 仍略差；Batch = 64 與 Epochs = 100 均表現不佳。
- **Dropout**：加入後誤差全面惡化，顯示台股股價具有強趨勢連續性，不適合隨機丟棄策略。

4 特徵選擇實驗（Feature Selection）

4.1 實驗設定

本實驗嘗試在最佳模型基礎上加入多維技術指標，觀察多特徵輸入是否能進一步提升預測準確度。本實驗將框架升級為 PyTorch，並加入六項技術指標，合計七個輸入特徵，所有特徵均依其數值分布特性採用各自獨立的正規化方式。

七個輸入特徵及其正規化策略如表 7 所示。

Table 7: 多特徵模型輸入特徵說明

#	特徵	正規化方式	意義
1	Close	log_return z-score	主要預測目標
2	RSI-14	$\div 100$	超買／超賣動能
3	MACD	StandardScaler	中短期趨勢
4	Volume_ratio	clip(0,5) + MinMax	量能強弱
5	Price_range	clip(0,0.2) + MinMax	當日波動幅度
6	Open_gap	clip($\pm 10\%$) + StandardScaler	隔夜跳空率
7	Week_trend	clip($\pm 15\%$) + StandardScaler	過去一週趨勢強弱

模型由 Keras 升級為 PyTorch 實作，架構設定如下：LSTM(128) $\rightarrow$ LSTM(64) $\rightarrow$ Dropout(0.2) $\rightarrow$ Attention $\rightarrow$ Linear(1)，look_back = 30 天，SEED = 7，採用 Huber Loss 與方向性懲罰的複合損失函數，並搭配後處理平滑管線（EMA 平滑 + 單步上限 ± 45 TWD）還原最終預測價格。各特徵分別 fit scaler，確保不發生資料洩漏（Data Leakage）。

4.2 實驗結果

Table 8: 特徵選擇實驗比較結果

模型 Test MAE	Train RMSE Test MAPE	Train MAE	Train MAPE	Test RMSE
Close only (Baseline, Keras)	13.9449	11.0807	1.89%	28.5012
22.3481	1.78%			
7 特徵多指標 (PyTorch)	12.9017	10.0712	2.93%	34.2219
26.8114	1.64%			

4.3 結果分析

加入七維技術指標並升級至 PyTorch 框架後，**測試 MAPE 從 1.78% 降至 1.64%**，訓練 RMSE 亦從 13.94 下降至 12.90，顯示模型對股價百分比誤差的預測能力有所提升。

測試 RMSE 由 28.50 升至 34.22，此差異源於本實驗同步調整了數項設計，與 Baseline 並非等條件比較：

- **預測目標改為 log-return 殘差**：模型學習預測當日報酬相對於前日的殘差而非絕對價格，後處理管線的 ± 45 TWD 單步上限在極端波動日（如 Day 9 單日漲 95 元）會限制追蹤幅度，偶發性大誤差拉高 RMSE。
- **視窗長度縮短 (100 $\rightarrow$ 30)**：較短視窗降低遠期雜訊，使模型對近期動能指標（RSI、MACD）反應更靈敏，但同時也更容易受短期波動干擾。
- **各特徵獨立正規化**：Close 使用 log-return z-score，RSI 除以 100，MACD、Open_gap、Week_trend 使用 StandardScaler，Volume_ratio 與 Price_range 使用 MinMaxScaler，有效解決多特徵尺度差異問題，但引入更複雜的輸入空間亦使訓練難度提升。

由於 MAPE 比 RMSE 更能反映模型在不同價位水準下的預測一致性，測試 MAPE 1.64% 低於 Baseline 的 1.78% 代表多特徵模型的相對預測精度確實優於單特徵 Baseline。後續 Phase 2 滾動預測與 Phase 3 交易決策均採用此 PyTorch 多特徵框架。

5 滾動預測模擬 (Phase 2: Rolling Forecast)

5.1 實作方法

本階段基於 Phase 1 特徵選擇所建立的 PyTorch 多特徵模型，模擬真實交易情境中的每日預測流程。與一次性預測整段測試集不同，Rolling Forecast 每次僅預測下一個交易日的收盤價，觀察真實價格後將其加入歷史序列，再預測下一天，如此循環 10 個交易日。

本實驗採用以下設計：

- **Random Seed 固定**：設定 SEED = 7，確保結果可重現
- **預測策略**：模型訓練一次後固定權重，每天將新實際值加入序列後滾動預測
- **預測期間**：2026/03/20 ~ 2026/04/02，共 10 個交易日

5.2 滾動預測結果

10 天滾動預測結果如表 9，誤差以 $\text{Pred} - \text{Actual}$ 表示（正值代表高估）。

Table 9: Rolling Forecast 逐日預測結果 (2026/03/20–2026/04/02)

Day	日期	實際 收盤	漲跌 (TWD)	預測 收盤	誤差 (TWD)	方向 正確
1	2026-03-20	1840	−10	1839	−1.09	是
2	2026-03-23	1810	−30	1839	+29.40	否
3	2026-03-24	1810	0	1827	+17.43	是
4	2026-03-25	1845	+35	1822	−22.65	否
5	2026-03-26	1840	−5	1835	−5.42	是
6	2026-03-27	1820	−20	1837	+17.05	否
7	2026-03-30	1780	−40	1830	+50.29	是
8	2026-03-31	1760	−20	1810	+50.12	是
9	2026-04-01	1855	+95	1792	−63.21	否
10	2026-04-02	1810	−45	1819	+9.42	是
Model Rolling RMSE			33.3583 NTD		MAPE : 1.47%	
Naive Baseline RMSE			64.2437 NTD		MAPE : 2.65%	
方向正確率			6 / 10 (60%)			




Figure 1: Rolling Forecast

5.3 結果分析

Rolling Forecast 的 MAPE (1.47%) 不僅低於 Phase 1 Baseline 測試 MAPE (1.78%)，更顯著優於 Naive Baseline (2.65%)，Rolling RMSE (33.36 NTD) 亦遠低於 Naive (64.24 NTD)，驗證模型學到超越「延續昨日趨勢」的有效資訊。

誤差最大的區間為 Day 7-8 (各約 +50 NTD) 與 Day 9 (-63.21 NTD)：

- **Day 7-8 (3/30-3/31)：**台積電連續下跌，模型持續高估，後處理管線的 ± 45 TWD 單步上限限制了對強下跌行情的追蹤能力。
- **Day 9 (4/01)：**台積電單日大漲 95 元 (+5.4%)，超出後處理硬上限，模型低估幅度最大。

後處理管線在平穩市況下降低預測雜訊，但台積電出現極端單日波動時限制了追蹤能力，此系統性偏差在 Phase 3 交易決策中則進行手動干預。

6 實盤交易競賽 (Phase 3: Live Trading Competition)

6.1 交易規則與策略說明

本階段以虛擬資金 10,000,000 TWD 參與為期兩週的模擬交易競賽，交易標的為台積電 (2330.TW)，競賽期間為 2026/03/20 ~ 2026/04/02，共 10 個交易日。

6.2 每日交易紀錄

表 10 為競賽期間每日的交易決策與資產變化紀錄。

Table 10: 每日交易紀錄

日期	實際收盤價	預測明日價	決策	交易股數	交易金額 (TWD)	現金餘額 (TWD)	總資產 (TWD)
2026-03-20	1,840	1,810.20	HOLD	0	0	10,000,000	10,000,000
2026-03-23	1,810	1,810.94	BUY	600	1,086,000	8,914,000	—
2026-03-24	1,810	1,813.05	BUY	1,350	2,443,500	6,470,500	—
2026-03-25	1,845	1,857.86	HOLD	0	0	6,470,500	—
2026-03-26	1,840	1,841.75	HOLD	0	0	6,470,500	—
2026-03-27	1,820	1,817.75	HOLD	0	0	6,470,500	—
2026-03-30	1,780	1,772.76	HOLD	0	0	6,470,500	—
2026-03-31	1,760	1,757.46	BUY	3,676	6,469,760	740	—
2026-04-01	1,855	1,863.56	SELL	5,620	10,425,100	10,425,840	—
2026-04-02	1,810	1,801.40	SELL	6	10,860	10,436,700	10,436,700
結果	—	—	SELL	5,626	—	—	10,436,700

6.3 績效分析

Table 11: 交易績效摘要

指標	數值
初始資金 (TWD)	10,000,000
最終總資產 (TWD)	10,436,700
ROI (投資報酬率)	4.37%
總交易次數	5

6.4 決策說明

- **Day 1 (3/20) : HOLD** 模型預測明日下跌 (1,810.20 vs 1,840)，觸發賣出邏輯，但由於初始持股為零，故維持 HOLD，保留全部現金等待更佳買點。
- **Day 2–3 (3/23–3/24) : BUY** 模型預測台積電將回升，依序試單 600 股及 1,350 股，以 1,810 元低點分批建立多頭部位。
- **Day 4–7 (3/25–3/30) : HOLD** 預測訊號未超過買賣門檻，觀望不動，避免在震盪期過度交易。
- **Day 8 (3/31) : BUY** 當日台積電股票來到新低點，以幾乎全部剩餘現金 (6,469,760 TWD) 買入 3,676 股 (當日收盤價 1,760 元)，完成主要建倉。
- **Day 9 (4/01) : SELL** 隔日台積電大漲至 1,855 元，模型預測可能少量上漲，惟近期台積電趨勢不穩定，因此賣出 5,620 股，僅保留少量部位等待進一步上漲。
- **Day 10 (4/02) : SELL (清倉)** 競賽最終日台積電股票再次下跌，亦強制清倉，以 1,810 元賣出剩餘 6 股，完成整場交易並計算最終資產。

6.5 反思與檢討

本次競賽最終 ROI 為 +4.37%，在 10 個交易日內達到正報酬。主要獲利來源為 Day 8 的大量建倉 (1,760 元) 及 Day 9 的大量出場 (1,855 元)，單日上漲幅度約 5.4%，此為競賽期間最大的單日漲幅。

模型表現分析： 價格預測大致依照模型預測的走向，模型在趨勢相對平穩的時期 (Day 4–7) 能正確維持 HOLD 的保守策略，避免在震盪期的無謂交易損耗。Day 8 的大量買入訊號捕捉到台積電的低點，顯示模型對強反彈的識別能力。

手動干預說明： 競賽期間恰逢中東局勢緊張影響全球股市，因此在部分天數採取手動干預策略，於模型發出弱訊號時選擇 HOLD 而非試單，使整體策略較貼近實際市場情形。此干預主要反映在 Day 3 (3/24) 保留小量部位而非賣出，以及 Day 9 (4/01) 選擇多數出場。

改進方向：

- 引入**情緒指標** (如 VIX、新聞情緒分析) 以應對突發地緣政治事件
- 加入**停損機制** (Stop-Loss)，限制單日最大虧損比率
- 計算**最大回撤** (Max Drawdown) 並納入風控指標，避免過度集中押注

7 結論

本實驗從 Keras 單特徵 LSTM Baseline 出發，透過系統性的超參數調整 (sequence length、model architecture、learning rate、dropout) 確立最佳的基礎設定 ([128, 64]、look_back = 100)。進一步將框架升級為 PyTorch，引入七維技術指標特徵、殘差預測目標、方向性 Huber Loss、AdamW 優化器及多層後處理管線，全面改善了模型的訓練穩定性與預測品質，測試 MAPE 由 1.78% 降至 1.64%。

Rolling Forecast 模擬顯示模型在 10 個交易日內達到 60% 的方向準確率，MAPE (1.47%) 遠優於 Naive Baseline (2.65%)，Live Trading 競賽則以 +4.37% 的 ROI 結束，驗證 LSTM + Attention 框架在實際金融決策上的應用潛力。未來可進一步結合情緒分析、Transformer 架構與線上學習機制，持續提升模型的適應能力。